



Projeto Aplicado II - Etapa 1

Integrantes:

Alexandre Zamarion Cepeda
Felipe Gabriel Lopes Pinheiro Clarindo
Thiago Godeguesi
Victória Martins Fortes

Professor:

Felipe Albino dos Santos

1. Premissas do Projeto

Organização:

A empresa fictícia criada será denominada Internet Movies DataBase Analytics (IMDb) , especializada em soluções de análise preditiva voltadas para filmes.

Área de Atuação: A IMDb atua no setor de recomendações de filmes, com ênfase em modelos de aprendizado de máquina para entender a recomendação dos usuários, prever a classificação dos melhores filmes segundo a classificação, entender o sentimento referente aos filmes e a classificação dos usuários.

Tipo de dado: texto (reviews de filmes em linguagem natural, com rótulo binário *positive/negative*).

Base de Dados Utilizada:

- Nome: IMDb Dataset of 50K Movie Reviews.
- Fonte: Kaggle (Lakshmi N). - Formato: CSV.
- Tamanho: ~50.000 registros dos usuários.
- Contexto: Dados de review dos filmes, feito por usuários, juntamente com os sentimento das reviews dos usuários.

Link: [Kaggle](#)

Metadados relevantes:

- Review
- Sentiment

2. Estrutura dos Dados (principais variáveis)

Variável	Descrição
review	Texto com a review do usuário
sentiment	Informação se o sentimento é positivo ou negativo.

3. Objetivos e Metas

Objetivo Geral:

Construir um modelo de classificação preditiva para identificar, a partir de dados das reviews, o sentimento, a nuvem de palavras, e análise mais avançadas em achar padrões.

Objetivos Específicos:

- Coletar e organizar a base (IMDb 50K), registrando fonte e licença.
- Fazer EDA básica: balanceamento de classes, tamanho dos textos e exemplos.
- Limpar e preparar o texto: lowercase, remoção de HTML/URLs/stopwords e tokenização.
- Representar o texto com TF-IDF (unigramas).
- Treinar Regressão Logística (baseline).
- Avaliar por F1 (principal) + Precisão e Recall.
- Entregar relatório técnico curto com achados e próximos passos.
- Tipo de dado: texto (reviews de filmes em linguagem natural, com rótulo binário *positive/negative*).

Metas Temporais:

- Curto prazo (30 dias): Preparação e análise exploratória.
- Médio prazo (60 dias): Treinamento e avaliação de modelos.
- Longo prazo (90 dias): Relatório técnico final e painel de resultados.

4. Cronograma de Atividades (Estimado)

Fase	Atividade	Período	Responsáveis
1	Definição do grupo, empresa e dataset	Semana 1–2	Todos
2	Coleta, limpeza e preparação dos dados	Semana 3–4	Alexandre e Felipe
3	Análise exploratória (EDA)	Semana 5–6	Thiago

4	Implementação dos modelos preditivos	Semana 7–8	Victória
5	Avaliação dos modelos e métricas	Semana 9–10	Todos
6	Relatório técnico e documentação no GitHub	Semana 11–12	Todos
7	Apresentação final	Semana 13	Todos

5. Estrutura do Documento

Este documento contempla: grupo de trabalho, premissas do projeto, estrutura dos dados, objetivos e metas, cronograma de atividades

6. Link para o GitHub

[GitHub](#)

<https://github.com/Projeto-Aplicado-Mackenzie-2025-2/projetooaplicado2-2025>

7. Justificativa Acadêmica e Profissional

A escolha do IMDb 50K Movie Reviews é adequada para NLP: permite comparar representações textuais (Bag-of-Words/TF-IDF/embeddings) e classificadores supervisionados (Regressão Logística/SVM), avaliando F1/Recall/Precisão em um problema clássico de análise de sentimentos.

Profissionalmente, esse tipo de modelo apoia monitoramento de percepção, curadoria editorial e sistemas de recomendação em plataformas de mídia.

Do ponto de vista acadêmico, o dataset possibilita explorar técnicas de:

- Estatística descritiva de texto: distribuição de classes, comprimento dos reviews, vocabulário e n-grams.
- NLP supervisionado (classificação de sentimento): treinamento e comparação de modelos.
- Representações textuais: Bag-of-Words e TF-IDF (opcional: embeddings).
- Pré-processamento linguístico: limpeza (lowercase, remoção de HTML/URLs/stopwords) e tokenização.
- Avaliação de desempenho: F1 (principal), Precisão, Recall e matriz de confusão (opcional: PR-AUC).
- Relato técnico e comunicação dos resultados (storytelling dos achados).